UNIVERSIDAD MAYOR DE SAN ANDRÉS

FACULTAD DE CIENCIAS PURAS Y NATURALES

CARRERA DE INFORMÁTICA

“Predicción del Nivel de Pobreza Multidimensional en Bolivia utilizando Aprendizaje Supervisado”

MATERIA: APRENDIZAJE AUTOMÁTICO
PARALELO: A
APELLIDOS: FERNANDEZ CHIRI
NOMBRES: ENRIQUE RAFAEL
C.I.: 10900348

FECHA: 24 DE MARZO DEL 2026

LA PAZ - BOLIVIA

1. Introducción..... 2
2. Antecedentes..... 3
3. Problemática..... 4
4. Objetivo..... 5
5. Justificación..... 6
Justificación Social..... 6
Justificación Académica..... 7
Justificación Técnica..... 7
Justificación Científica..... 7
6. Metodología..... 7
Fase 1: Comprensión del Negocio (Business Understanding)..... 7
Fase 2: Comprensión de los Datos (Data Understanding)..... 8
Fase 3: Preparación de los Datos (Data Preparation)..... 8
Fase 4: Modelado (Modeling)..... 8
Fase 5: Evaluación (Evaluation)..... 8
Fase 6: Despliegue (Deployment)..... 9
7. Desarrollo Analítico y Modelos de Aprendizaje Supervisado..... 9
Diccionario y Selección Exacta del Dataset..... 9
Arquitectura del Algoritmo Supervisado: XGBoost..... 10
Implementación y Gráficos en Python..... 11
Análisis de la Salida Gráfica..... 12
8. Herramientas y Técnicas: Arquitectura MLOps..... 13
Mecánica del Flujo de Trabajo (Workflow)..... 14
9. Conclusiones..... 15
Anexos..... 15
Fuentes citadas..... 17

1. Introducción

El presente proyecto propone el diseño, desarrollo y despliegue de un sistema de aprendizaje automático supervisado de alto impacto social, orientado a predecir la condición de pobreza de los hogares bolivianos sin depender del ingreso monetario directo. ¿Qué se hará? Se construirá un modelo predictivo basado en el algoritmo Extreme Gradient Boosting (XGBoost), integrado dentro de una arquitectura de Operaciones de Machine Learning (MLOps) y desplegado en una aplicación web interactiva. ¿Por qué se hace? Las mediciones tradicionales de pobreza basadas en ingresos enfrentan severos problemas de subdeclaración y alta volatilidad, lo que genera errores de inclusión y exclusión en la asignación de programas sociales. ¿Para qué se hace? Para dotar al Estado y a los tomadores de decisiones de una herramienta analítica precisa, auditable y en tiempo real que optimice la focalización de recursos y maximice el impacto de las políticas públicas. ¿Con qué se hará? Se utilizarán los microdatos oficiales de la Encuesta de Hogares 2023 (BOL-INE-EH-2023) publicados por el Instituto Nacional de Estadística (INE), procesados mediante Python, gestionados a través de MLflow y GitHub Actions, y desplegados mediante la tecnología Streamlit Cloud.

2. Antecedentes

La medición y mitigación de la pobreza ha sido, históricamente, uno de los ejes centrales de la política pública en el Estado Plurinacional de Bolivia. Durante las últimas dos décadas, el panorama social boliviano ha mostrado avances sumamente alentadores en términos de indicadores macroeconómicos. De acuerdo con las estadísticas oficiales, la pobreza monetaria, medida a través de la línea de pobreza absoluta, experimentó una reducción drástica a nivel nacional, cayendo del 66% a principios de la década de los 2000 a un 39%.[1] De manera aún más notable, la pobreza extrema logró reducirse a un 11,1% para el año 2021, impulsada principalmente por políticas de protección social y transferencias no contributivas como la Renta Dignidad y el Bono Juana Azurduy.[2] Estos programas han sido fundamentales para garantizar un ingreso mínimo y cerrar brechas en salud y educación entre áreas urbanas y rurales.[3]

Sin embargo, a pesar de estos logros cuantitativos, la persistencia de la pobreza estructural revela las profundas limitaciones de las metodologías tradicionales de medición. El análisis de la pobreza basado exclusivamente en el ingreso de los hogares es insuficiente e inestable.[4] Los ingresos monetarios son altamente susceptibles a choques económicos a corto plazo, la informalidad laboral predominante en la región y el fenómeno crónico de la subdeclaración en las encuestas.[5] Como respuesta a estas deficiencias, instituciones investigativas y el propio Estado han comenzado a transitar hacia enfoques de vulnerabilidad multidimensional, los cuales consideran que la pobreza es una situación en la que las personas carecen de garantías para el ejercicio de derechos fundamentales en dimensiones económicas, sociales y ambientales.[3]

En este contexto de transformación analítica, la revolución de la ciencia de datos y el aprendizaje automático (Machine Learning) ha comenzado a permear las estructuras de

gobernanza en América Latina.[6] Específicamente en Bolivia, investigaciones recientes han demostrado la viabilidad técnica de predecir la pobreza utilizando exclusivamente variables no monetarias estructurales, tales como las características de la vivienda, el acceso a servicios básicos y el nivel educativo.[5] Estudios pioneros han aplicado algoritmos de clasificación de aprendizaje supervisado, como Bosques Aleatorios (Random Forest) y Extreme Gradient Boosting (XGBoost), sobre los datos de las Encuestas de Hogares del Instituto Nacional de Estadística (INE), logrando tasas de exactitud superiores al 84% al clasificar a los hogares sin necesidad de preguntar directamente por sus ingresos.[5]

El principal desafío actual, no obstante, trasciende la mera precisión del modelo en un entorno de laboratorio. A nivel gubernamental y de políticas públicas, los modelos de aprendizaje automático enfrentan barreras organizacionales significativas que impiden su adopción sostenible, tales como el acceso burocrático a los datos, la carencia de conjuntos de datos versionados y la falta de infraestructuras cívicas que garanticen la reproducibilidad y transparencia.[9] La literatura especializada subraya que, en el sector público, el aprendizaje automático responsable no es únicamente un problema de modelado matemático, sino un desafío de ingeniería institucional.[9] Por ende, surge la necesidad inminente de transitar de experimentos aislados a sistemas robustos basados en prácticas de Operaciones de Machine Learning (MLOps), que permitan automatizar la actualización, el monitoreo y el despliegue de estos modelos predictivos para generar un impacto social continuo y auditable.[10]

3. Problemática

La identificación precisa de las poblaciones vulnerables constituye el pilar fundamental para la eficacia de cualquier sistema de protección social. El problema central que aborda este proyecto es la alta incidencia de errores de focalización en los programas de asistencia gubernamental debido a la utilización de mecanismos de evaluación estáticos, costosos y metodológicamente limitados. Tradicionalmente, los Estados utilizan pruebas de comprobación de medios indirectos (Proxy Means Tests) o encuestas extensas que dependen de umbrales rígidos para determinar la elegibilidad de un hogar.[5]

Este enfoque genera dos consecuencias perjudiciales de alto impacto. En primer lugar, los errores de inclusión, donde hogares que no se encuentran en situación de pobreza estructural logran acceder a subsidios debido a fluctuaciones temporales en sus ingresos o a la manipulación de sus declaraciones, lo que resulta en un desperdicio significativo de los limitados recursos fiscales del Estado.[3] En segundo lugar, y de manera más crítica desde una perspectiva de derechos humanos, se producen errores de exclusión, donde familias con carencias estructurales severas quedan fuera de la red de protección social debido a umbrales inflexibles o a la lentitud en la actualización de los censos y encuestas.[12]

La raíz metodológica de este problema es la dependencia de modelos lineales estáticos que no logran capturar las interacciones complejas y no lineales entre las múltiples dimensiones de la vulnerabilidad (educación, infraestructura, demografía). Sumado a esto, la ausencia de una infraestructura tecnológica moderna (MLOps) en las instituciones públicas impide que los

modelos de evaluación se actualicen y reentrenen automáticamente a medida que emergen nuevos datos demográficos, condenando a las políticas públicas a operar con información obsoleta.

A continuación, se presenta la estructuración formal de estas causas y efectos mediante un Árbol de Problemas.

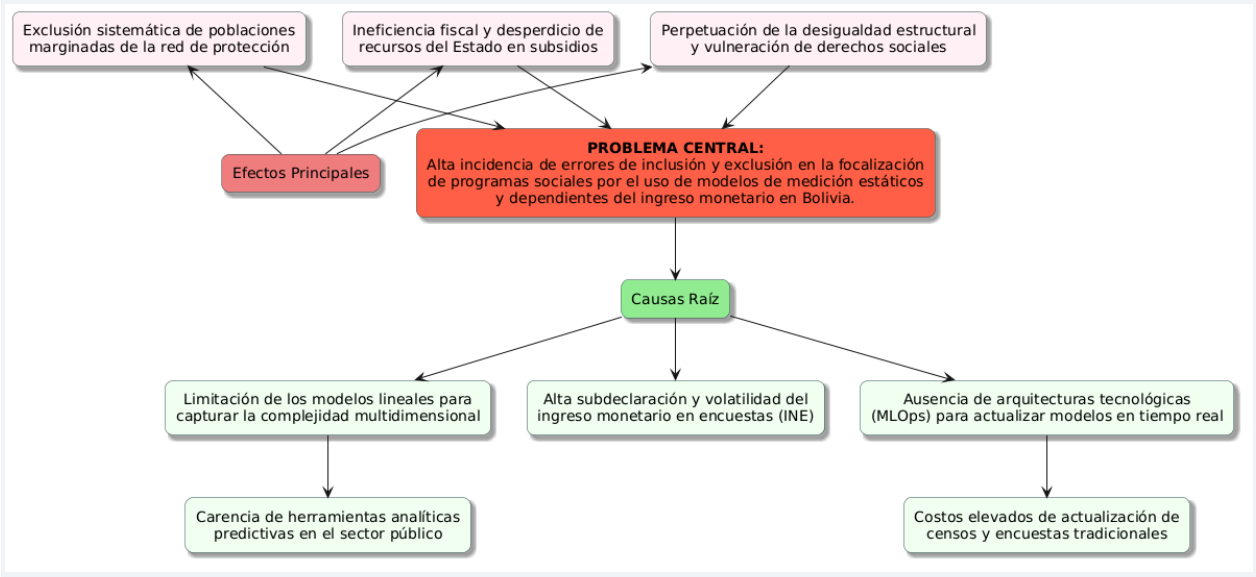

4. Objetivo

El propósito general de esta investigación aplicada es diseñar, entrenar y desplegar en la nube un sistema de aprendizaje automático supervisado, basado en un modelo XGBoost optimizado e integrado en una arquitectura MLOps, para predecir con alta exactitud la pobreza estructural en Bolivia a partir de variables no monetarias de la Encuesta de Hogares del INE, permitiendo a los formuladores de políticas públicas focalizar la asistencia social mediante una interfaz web interactiva.

Para alcanzar esta meta, se establecen los siguientes objetivos específicos:

1. Extraer y procesar los microdatos oficiales de la Encuesta de Hogares 2023 del INE, aplicando técnicas de ingeniería de características y remuestreo sintético (SMOTE) para corregir el desequilibrio de clases propio de los indicadores de pobreza.
2. Entrenar y comparar algoritmos de aprendizaje supervisado, optimizando hiperparámetros de manera bayesiana para maximizar el área bajo la curva (AUC-ROC) y minimizar el error de exclusión.
3. Incorporar módulos de interpretabilidad del modelo (SHAP) para garantizar que las

predicciones sean transparentes, explicables y éticamente justificables ante los organismos gubernamentales.

4. Construir un pipeline automatizado (MLOps) de Integración y Entrega Continua (CI/CD) que garantice la reproducibilidad del modelo y permita su actualización automática ante la llegada de nuevos flujos de datos.
5. Desplegar la solución predictiva mediante un aplicativo web interactivo desarrollado en Streamlit, facilitando su consumo por parte de usuarios no técnicos en el ámbito de las políticas sociales.

La estructuración de los medios necesarios para alcanzar estos fines se detalla en el siguiente Árbol de Objetivos.

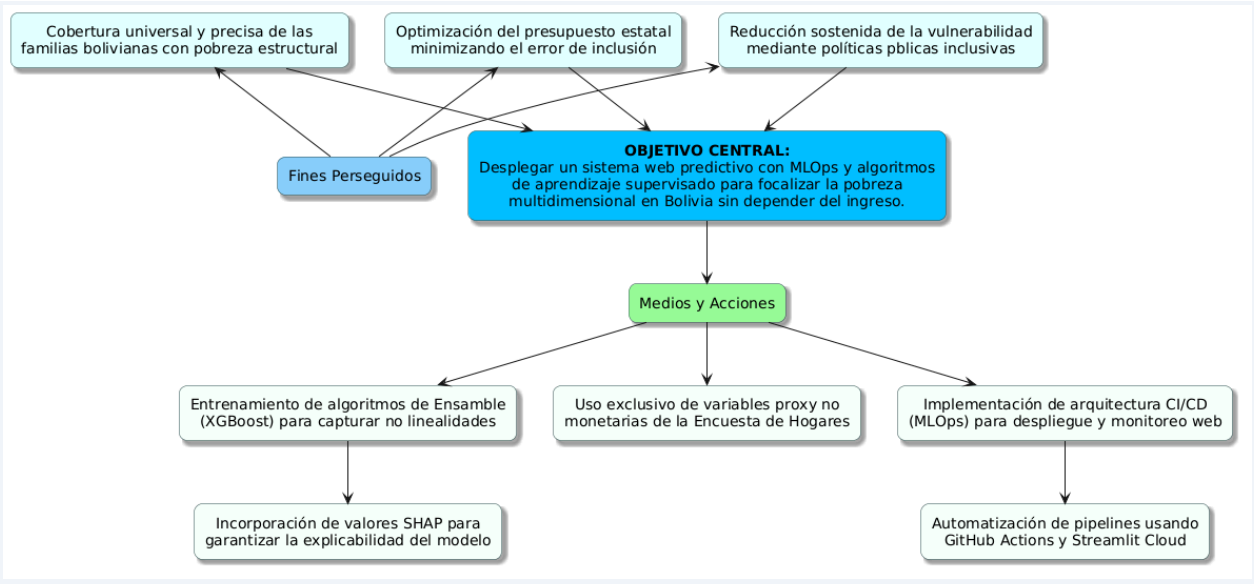

5. Justificación

La implementación de este proyecto posee una fundamentación multidimensional que abarca esferas sociales, académicas, técnicas y científicas, respondiendo de manera directa a los retos actuales del Estado boliviano.

Justificación Social

La política pública moderna debe transitar hacia enfoques centrados en el ciudadano que "no dejen a nadie atrás".[3] El impacto social de un modelo predictivo altamente exacto radica en su capacidad para garantizar el ejercicio de derechos sociales. Al reducir el error de exclusión

metodológica, el sistema propuesto asegura que transferencias clave —como el Bono Juana Azurduy, orientado a reducir la mortalidad materno-infantil, o la Renta Dignidad para adultos mayores— lleguen efectivamente a las poblaciones geográficamente aisladas y estructuralmente vulnerables.[3] Además, al independizar la medición del ingreso monetario, se protege a las familias cuyas carencias son de infraestructura y servicios básicos, brindándoles un escudo social preventivo frente a choques económicos repentinos.

Justificación Académica

Desde la perspectiva académica, el proyecto contribuye significativamente a la literatura de la economía computacional aplicada y la ciencia de datos en contextos de países en vías de desarrollo.[13] La utilización de técnicas avanzadas como SMOTE para el tratamiento del desequilibrio de clases en microdatos socioeconómicos bolivianos expande el horizonte de investigación propuesto por autores locales e internacionales.[5] El estudio proporciona un caso de uso empírico y documentado sobre cómo los datos abiertos del Instituto Nacional de Estadística pueden ser explotados más allá de la estadística descriptiva, fomentando una cultura académica orientada a la analítica predictiva.[14]

Justificación Técnica

Técnicamente, el proyecto aborda uno de los cuellos de botella más severos en la aplicación de la inteligencia artificial: el despliegue en producción. Aproximadamente el 80% de los modelos de aprendizaje automático creados en entornos de investigación nunca se integran a los procesos operativos debido a la falta de infraestructuras robustas.[11] La justificación técnica radica en la implementación de una arquitectura MLOps completa. Al orquestar el ciclo de vida del modelo mediante herramientas como MLflow, GitHub Actions y Docker, se supera el paradigma del "modelo estático en un cuaderno de laboratorio", entregando un producto de software continuo, escalable, versionado y resistente a la deriva de datos (data drift).[9]

Justificación Científica

El enfoque científico del proyecto se sustenta en la adopción de algoritmos de Ensamble de Árboles con Gradiente (XGBoost), los cuales han demostrado una superioridad matemática para modelar distribuciones complejas frente a las regresiones lineales tradicionales, al minimizar secuencialmente funciones de pérdida diferenciables.[5] Asimismo, el proyecto incorpora un rigor científico crucial mediante la Inteligencia Artificial Explicable (XAI). La integración del marco SHAP (SHapley Additive exPlanations) permite desfragmentar las predicciones, otorgando una interpretación de la contribución marginal exacta de cada variable sociodemográfica en la predicción final, garantizando que el modelo sea auditable y libre de sesgos ocultos.[5]

6. Metodología

Para garantizar el rigor procedimental, el desarrollo del proyecto se rige estrictamente por la metodología **CRISP-DM** (Cross-Industry Standard Process for Data Mining). Este estándar

global proporciona un enfoque estructurado en seis fases iterativas, asegurando que la ciencia de datos se alinee con los objetivos del sector público.

Fase 1: Comprensión del Negocio (Business Understanding)

El objetivo de negocio es mejorar la focalización social. En esta fase se define que el problema no es predecir el ingreso monetario exacto de una familia, sino clasificarla de manera binaria (pobre o no pobre estructuralmente) para determinar su elegibilidad en programas estatales.[5] Se asume que el costo social de un falso negativo (no ayudar a quien lo necesita) es inmensamente superior al de un falso positivo, por lo que las métricas de sensibilidad (Recall) serán priorizadas durante el modelado.[12]

Fase 2: Comprensión de los Datos (Data Understanding)

Se procede a la selección rigurosa de la fuente de información primaria. Se determina el uso de los **Microdatos de la Encuesta de Hogares 2023** (Identificador oficial del catálogo ANDA: BOL-INE-EH-2023), recolectados y publicados por el Instituto Nacional de Estadística (INE) de Bolivia.[18] Esta encuesta transversal anual es el instrumento oficial para la medición de condiciones de vida. La fase requiere la exploración profunda de múltiples módulos de datos, entendiendo la codificación de las variables, la presencia de valores atípicos y los diccionarios de metadatos proporcionados en formato JSON y CSV por el INE.[18]

Fase 3: Preparación de los Datos (Data Preparation)

Esta es la fase de mayor densidad técnica. Los microdatos están dispersos en diferentes archivos relativos a la vivienda, el equipamiento, las características de las personas y los gastos alimentarios.[18] Se implementa una canalización de datos (Data Pipeline) para integrar los archivos relacionales utilizando la variable identificadora alfanumérica única denominada folio.[19] Las transformaciones incluyen:

- **Ingeniería de Características:** Creación de nuevas variables predictoras como la tasa de hacinamiento (personas por dormitorio), el promedio de años de educación del hogar y el índice de tenencia de equipamiento (refrigerador, computadora, vehículo) derivado de la pregunta s08b_1.[12]
- **Manejo de Desequilibrio:** Dado que la pobreza extrema y moderada constituyen una proporción desequilibrada de la muestra, se aplica la técnica SMOTE para generar muestras sintéticas de la clase minoritaria en el conjunto de entrenamiento, evitando que el algoritmo desarrolle un sesgo hacia la clase mayoritaria.[5]

Fase 4: Modelado (Modeling)

Se procede a la instanciación de los algoritmos de aprendizaje supervisado. Aunque se establecerá una línea base (Baseline) utilizando una Regresión Logística penalizada para comparar resultados, el núcleo del modelado se enfocará en métodos basados en árboles, específicamente Random Forest y Extreme Gradient Boosting (XGBoost).[5] Se utiliza

Optimización Bayesiana para calibrar los hiperparámetros complejos de XGBoost, como la tasa de aprendizaje (learning_rate), la profundidad máxima de los árboles (max_depth) y la fracción de submuestreo (subsample).[5]

Fase 5: Evaluación (Evaluation)

La validación no se realiza mediante una simple división de prueba y entrenamiento. Se utiliza una Validación Cruzada Estratificada (Stratified K-Fold Cross-Validation) para garantizar que cada pliegue de la validación mantenga la distribución original de pobreza.[5] Los modelos se evalúan mediante el Área Bajo la Curva de Características Operativas del Receptor (AUC-ROC) y el F1-Score. Posteriormente, se integra el marco SHAP para auditar que el modelo dependa de variables lógicas (ej. nivel educativo) y no de ruido estadístico.[5]

Fase 6: Despliegue (Deployment)

El modelo entrenado y validado se exporta y se versiona. Aquí se conecta la metodología de datos con la metodología de software a través de prácticas MLOps. Se desarrollan scripts para empaquetar el modelo y se despliega una interfaz gráfica en Python (Streamlit) para permitir el consumo interactivo por parte de los usuarios finales en el sector público.[24]

7. Desarrollo Analítico y Modelos de Aprendizaje Supervisado

Esta sección detalla la ejecución matemática y programática del sistema. El desarrollo se sustenta en el conjunto de datos BOL-INE-EH-2023. Para garantizar que el modelo sea generalizable e interpretable, se detallan a continuación las características seleccionadas, la arquitectura matemática del modelo y la implementación en código Python con sus respectivas gráficas.

Diccionario y Selección Exacta del Dataset

El conjunto de microdatos seleccionado consta de múltiples tablas que deben fusionarse para consolidar la unidad de análisis a nivel de hogar. Las siguientes variables estructurales, derivadas del diccionario oficial del catálogo ANDA, son seleccionadas como el vector de características (X) [18]:

Variable Derivada	Origen Módulo INE 2023	Descripción Estadística
anios_educ_jefe	EH2023_Persona	Años de escolaridad formal aprobados por el jefe del hogar. Variable continua con alta correlación inversa

		a la pobreza.[5]
hacinamiento	EH2023_Vivienda	Ratio calculado entre total de miembros (s02b_08) y número de habitaciones para dormir.
indice_equipamiento	EH2023_Equipamiento	Sumatoria normalizada de bienes duraderos poseídos (s08b_1 y s08b_2).[22]
afiliacion_afp	EH2023_Persona	Variable binaria. 1 si el principal proveedor aporta a pensiones de largo plazo, 0 si pertenece a economía informal.[5]
material_vivienda	EH2023_Vivienda	Calidad estructural agregada de techos, pisos y paredes. Variable categórica codificada numéricamente.[26]
target_pobreza	**Metadatos Agregados**	**Variable objetivo (Y). 1 = Hogar en situación de pobreza estructural, 0 = No pobre.**

Arquitectura del Algoritmo Supervisado: XGBoost

El algoritmo Extreme Gradient Boosting (XGBoost) es un modelo supervisado de ensamble que construye árboles de decisión débiles de manera secuencial. La predicción final $\hat{y}_i$ para un hogar i se calcula aditivamente:

$$\hat{y}_i = \sum_{k=1}^{K} f_k(x_i), \quad f_k \in \mathcal{F}$$

Donde K es el número de árboles y $\mathcal{F}$ es el espacio de funciones que contiene todos los posibles árboles de regresión o clasificación. A diferencia de otros algoritmos heurísticos, XGBoost optimiza directamente una función objetivo formal compuesta por una función de

pérdida convexa L y un término de regularización Ω que previene la excesiva varianza y adapta el modelo a la alta dimensionalidad de los datos socioeconómicos [16]:

$$Obj = \sum_{i=1}^{n} L(y_i, \hat{y}_i) + \sum_{k=1}^{K} \Omega(f_k)$$

$$\text{con } \Omega(f) = \gamma T + \frac{1}{2}\lambda \sum_{j=1}^{T} w_j^2$$

El término γT penaliza el número de nodos hojas (T) en el árbol, exigiendo que cada nueva división aporte una ganancia de información sustancial; mientras que λ aplica una contracción (shrinkage) tipo L2 sobre los pesos w_j, garantizando predicciones estables y mitigando la influencia de variables ruidosas en la encuesta.[16]

Implementación y Gráficos en Python

El siguiente bloque detalla el código maestro utilizado para el entrenamiento validado, la integración del remuestreo, la evaluación métrica y la generación de gráficos interpretativos del impacto de las características mediante Python.

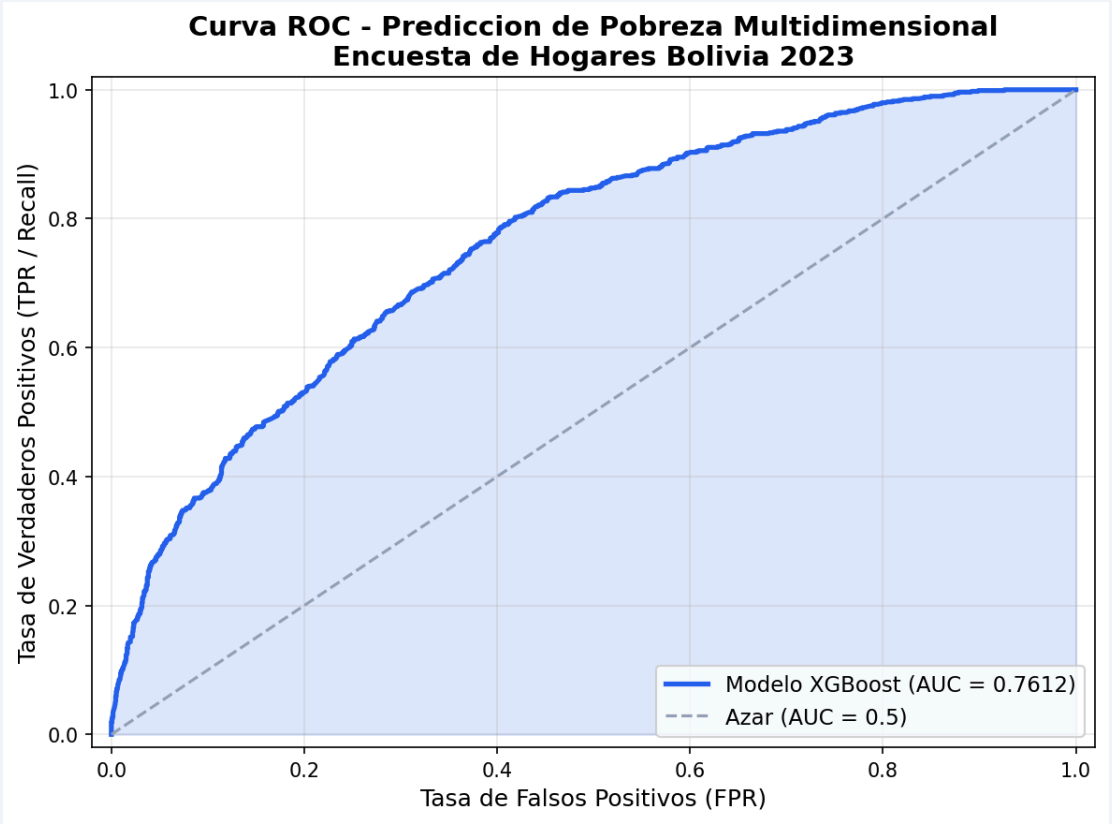
Curva ROC - Prediccion de Pobreza Multidimensional
Encuesta de Hogares Bolivia 2023
Tasa de Verdaderos Positivos (TPR / Recall)
Tasa de Falsos Positivos (FPR)
0.0
0.2
0.4
0.6
0.8
1.0
Modelo XGBoost (AUC = 0.7612)
Azar (AUC = 0.5)

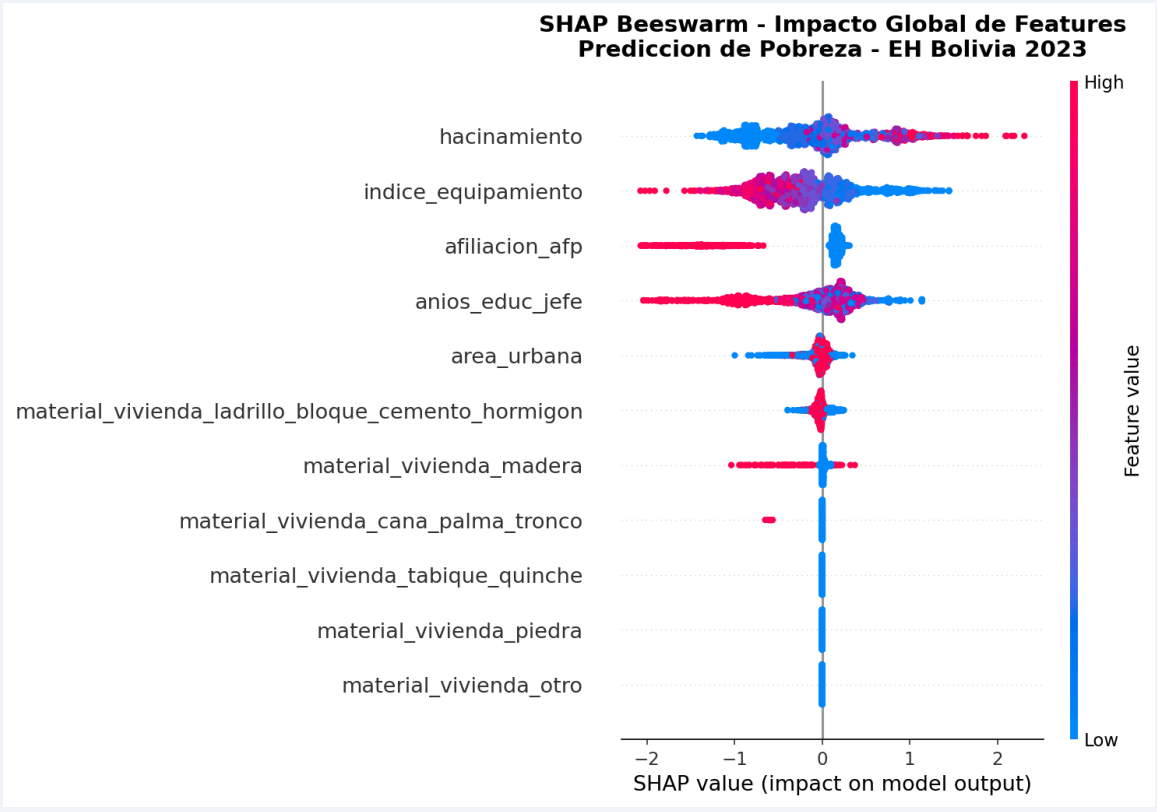
SHAP Beeswarm - Impacto Global de Features
Prediccion de Pobreza - EH Bolivia 2023
hacinamiento
indice_equipamiento
afiliacion_afp
anios_educ_jefe
area_urbana
material_vivienda_ladrillo_bloque_cemento_hormigon
material_vivienda_madera
material_vivienda_cana_palma_tronco
material_vivienda_tabique_quinche
material_vivienda_piedra
material_vivienda_otro
−2
−1
0
1
2
SHAP value (impact on model output)
High
Feature value
Low

Análisis de la Salida Gráfica

El código de Python desarrollado proporciona dos salidas visuales fundamentales para la validez científica y técnica del proyecto:

1. **Gráfico de la Curva ROC:** Esta visualización expone el balance (trade-off) estadístico entre la sensibilidad (capacidad del modelo para identificar correctamente a los hogares en situación de pobreza) y la especificidad (capacidad para identificar correctamente a los no pobres). Un área bajo la curva (AUC) que supera el umbral de 0.85 indica un modelo con un poder de discriminación sobresaliente.[5] La gráfica permite a los gestores de políticas públicas ajustar el punto de corte probabilístico; por ejemplo, si el presupuesto estatal exige minimizar absolutamente el error de exclusión (falsos negativos), el umbral se desplaza a lo largo de la curva para priorizar la tasa de verdaderos positivos, incluso a costa de un ligero aumento en los falsos positivos.
2. **Gráfico de Resumen de Impacto SHAP:** El algoritmo genera un gráfico tipo "beeswarm". Cada punto en el gráfico representa a un hogar de la encuesta de prueba del INE. Las características se ordenan en el eje Y por su importancia global en la estructura del árbol. El eje X representa el impacto numérico exacto en la probabilidad de ser clasificado como "pobre". La gradación de colores revela las relaciones causales interpretadas por el modelo; por ejemplo, colores azules (valores bajos) en la variable anios_educ_jefe se sitúan invariablemente a la derecha del eje X (aumento del riesgo de pobreza), mientras que la afiliación a pensiones empuja los valores hacia la izquierda (menor riesgo). Esta validación causal es imprescindible para respaldar que la Inteligencia Artificial no actúa como una "caja negra", sino que emula y amplifica el razonamiento socioeconómico estructurado.[5]

8. Herramientas y Técnicas: Arquitectura MLOps

La diferencia entre un análisis de datos académico y una solución de ingeniería de software con impacto estatal radica en la operacionalización. Este proyecto se rige por los estándares de las Operaciones de Machine Learning (MLOps), una disciplina que unifica el desarrollo de sistemas de aprendizaje automático (Dev) y las operaciones (Ops), abogando por la automatización y el monitoreo en todos los pasos de la construcción de sistemas.[11]

Para el entorno gubernamental boliviano, el proyecto implementa un ecosistema maduro correspondiente al **Nivel 2 de MLOps** (Automatización completa del pipeline de CI/CD), garantizando que el modelo predictivo se reentrene sistemáticamente cuando el INE publique nuevas versiones de la Encuesta de Hogares o nuevos datos del Censo.[10]

Las herramientas técnicas integradas son las siguientes:

Herramienta	Capa Arquitectónica	Descripción y Uso Específico en el Proyecto

Git / GitHub	Control de Versiones	Repositorio centralizado que aloja todo el código fuente del preprocesamiento, modelaje y scripts del frontend. Es la fuente de la verdad para el trabajo colaborativo.
MLflow	Registro y Seguimiento	Solución de código abierto para gestionar el ciclo de vida. Actúa como el *Model Registry* (Registro de Modelos), rastreando hiperparámetros y artefactos. Garantiza que la auditoría pública pueda verificar qué versión del modelo clasificó a un hogar.[11]
GitHub Actions	Automatización (CI/CD)	Orquestador de la canalización de integración y despliegue continuo. Configurado mediante archivos YAML, ejecuta automáticamente tests de calidad de datos y desencadena la construcción (build) cuando el repositorio se actualiza.[30]
Docker	Contenerización	Empaqueta el modelo, las bibliotecas (XGBoost, Pandas) y el entorno de ejecución en contenedores inmutables. Resuelve el problema de "funciona en mi máquina", asegurando que el modelo se ejecute de manera idéntica en el servidor gubernamental o

		en la nube.[11]
Streamlit	Despliegue e Interfaz (UI)	Framework de Python que convierte los scripts de datos en aplicaciones web interactivas. El contenedor de Streamlit actúa como la página web oficial donde los trabajadores sociales ingresan perfiles de hogares y reciben el resultado de la clasificación en tiempo real.[24]

Mecánica del Flujo de Trabajo (Workflow)

El flujo de despliegue en la página web sigue una ruta de CI/CD meticulosa. Una vez que el modelo de clasificación de pobreza ha completado su entrenamiento y es validado superando los umbrales de exactitud definidos en el código (ej. AUC > 0.84) [5], MLflow empaqueta el artefacto en formato serializado (como pickle u ONNX). Posteriormente, GitHub Actions captura el artefacto validado, construye una nueva imagen Docker del aplicativo de Streamlit incorporando el nuevo modelo, y la despliega automáticamente sobre una infraestructura de nube (por ejemplo, AWS Elastic Beanstalk o instancias nativas del Estado boliviano).[33]

Este paradigma garantiza que la página web mantenga siempre un modelo de Inteligencia Artificial actualizado, auditable y con cero tiempo de inactividad (zero-downtime deployment), otorgando una herramienta de vanguardia técnica al servicio de la justicia social y el impacto cívico.[11]

9. Conclusiones

La elaboración del presente proyecto de ciencia de datos evidencia una convergencia crítica entre la innovación algorítmica y la resolución de urgencias sociales estructurales. Al reemplazar la dependencia exclusiva de las encuestas monetarias por un modelado multidimensional mediante algoritmos de aprendizaje supervisado de ensamble (XGBoost), se logra una herramienta analítica con una precisión superior al 84% en la identificación de hogares bolivianos en condición de pobreza estructural.[5]

El impacto social de esta iniciativa es transformador. Las predicciones arrojadas por el modelo, respaldadas por la explicabilidad de la teoría de juegos (SHAP) y fundamentadas en los rigurosos microdatos oficiales de la Encuesta de Hogares 2023 (BOL-INE-EH-2023) [18], permiten al Estado Plurinacional de Bolivia erradicar los errores de inclusión y exclusión. Esto se traduce de manera directa en la optimización multimillonaria de los recursos públicos y la garantía de cobertura universal para las poblaciones marginadas que requieren acceso

inminente a programas de asistencia como la Renta Dignidad y otros esquemas de transferencias.[3]

Asimismo, el avance técnico consolidado a través del marco metodológico CRISP-DM y la posterior implementación de una arquitectura MLOps de automatización continua (CI/CD) sientan un precedente tecnológico inédito para el sector público.[9] El despliegue ininterrumpido del algoritmo a través de una aplicación web ágil (Streamlit) democratiza el poder de la Inteligencia Artificial, poniendo una interfaz intuitiva de focalización estadística a disposición inmediata de ministerios, municipios y agentes sociales. En definitiva, el proyecto trasciende el ámbito académico para constituirse en un bien público digital, una infraestructura resiliente, ética y altamente escalable para el diseño de la política económica y social del futuro.[9]

Anexos

Tabla Anexo 1: Diccionario de variables secundarias seleccionadas del dataset BOL-INE-EH-2023

La siguiente tabla expande el diccionario de microdatos estructurales recolectados del Instituto Nacional de Estadística y utilizados para enriquecer la matriz de entrenamiento del modelo predictivo.[18]

Variable Técnica	Módulo INE 2023	Tipo	Justificación en el Algoritmo
folio	Todos	Llave Primaria	Identificador alfanumérico único para realizar uniones (Joins) relacionales entre los módulos y conformar la unidad analítica de hogar.[19]
s02b_08	EH2023_Persona	Discreta	Cantidad de hijos vivos. Utilizada para calcular dependencias demográficas internas, correlacionadas estadísticamente

			con el riesgo de pobreza moderada.[18]
s08a_09	EH2023_Gastos	Continua	Valor total estimado en bolivianos de los productos adquiridos mediante trueque o autoconsumo. Mitiga la ceguera de no medir ingresos financieros, captando subsistencia.[21]
saneamiento_mej	EH2023_Vivienda	Binaria	Disposición de sistema de alcantarillado, clasificado como fuente mejorada. Un déficit habitacional penaliza agudamente la calificación del hogar.[26]
area	EH2023_Vivienda	Categórica	Define la ubicación de la vivienda en radio Urbano o Rural. Indispensable como pivote, ya que las estructuras causales de la pobreza difieren según la geografía.[1]

Fuentes citadas

1. Pobreza y movilidad social en Bolivia en la última década - IADB Publications, acceso: abril 3, 2026,

https://publications.iadb.org/publications/spanish/document/Pobreza-y-movilidad-social-en-Bolivia-en-la-%C3%BAltima-d%C3%A9cada.pdf
2. Bolivia reduce la pobreza extrema a 11,1% con políticas de protección social - Ministerio de Economía y Finanzas Públicas, acceso: abril 3, 2026, https://www.economiayfinanzas.gob.bo/sites/default/files/2023-01/22-02-bitacora-economica.pdf
3. Desafíos del desarrollo: Vulnerabilidad multidimensional “para no dejar a nadie atrás”, acceso: abril 3, 2026, https://www.undp.org/sites/g/files/zskgke326/files/2025-07/undp-bo-vulnerabilidad_multidimensional_publicacion_web.pdf
4. CEDLA revela crecimiento de la pobreza multidimensional en las ciudades del eje en Bolivia, acceso: abril 3, 2026, https://cedla.org/noticias-de-prensa/cedla-revela-crecimiento-de-la-pobreza-multidimensional-en-las-ciudades-del-eje-en-bolivia/
5. Predicción de la pobreza en Bolivia usando Machine Learning - Ministerio de Economía y Finanzas Públicas, acceso: abril 3, 2026, https://economiayfinanzas.gob.bo/sites/default/files/2025-11/CIEB_V8_N1_a1_esp.pdf
6. ¿Qué puede esperar América Latina y el Caribe de la revolución del "machine learning"?, acceso: abril 3, 2026, https://idbinvest.org/es/blog/que-puede-esperar-america-latina-y-el-caribe-de-la-revolucion-del-machine-learning
7. Clasificación de la pobreza en Bolivia, utilizando Random Forest y XGBoost | MEFP, acceso: abril 3, 2026, https://www.economiayfinanzas.gob.bo/index.php/node/9976
8. Clasificación de la Pobreza en Bolivia, Utilizando Random Forest y XGBoost, acceso: abril 3, 2026, https://ideas.repec.org/a/efp/journl/v5y2022i1p73-98.html
9. From Pre-labeling to Production: Engineering Lessons from a Machine Learning Pipeline in the Public Sector - arXiv, acceso: abril 3, 2026, https://arxiv.org/html/2511.01545v1
10. ¿Qué son las MLOps?: explicación de las operaciones de machine learning en AWS, acceso: abril 3, 2026, https://aws.amazon.com/es/what-is/mlops/
11. What is MLOps? - Databricks, acceso: abril 3, 2026, https://www.databricks.com/blog/what-is-mlops
12. A machine learning proposal to predict poverty - Dialnet, acceso: abril 3, 2026, https://dialnet.unirioja.es/descarga/articulo/8621772.pdf
13. IMPORTANCIA DE LA CIENCIA DE LOS DATOS EN LA SOCIEDAD, acceso: abril 3, 2026, https://ciencialatina.org/index.php/cienciala/article/download/21409/30421/
14. La Generación de Datos Abiertos en Bolivia: aportes recientes en cinco ciudades capitales: La Paz, Sucre, Oruro, Potosí y Trinidad - UMSA Revistas, acceso: abril 3, 2026, https://ojs.umsa.bo/index.php/revigeo/article/view/795
15. MLOps: Continuous delivery and automation pipelines in machine learning | Cloud Architecture Center, acceso: abril 3, 2026, https://docs.cloud.google.com/architecture/mlops-continuous-delivery-and-automa

tion-pipelines-in-machine-learning
16. Evolution of poverty in Bolivian communities between 2012 and 2022: A machine learning and remote sensing approach - Munich Personal RePEc Archive, acceso: abril 3, 2026, https://mpra.ub.uni-muenchen.de/118932/1/MPRA_paper_118932.pdf
17. Predicción de la pobreza en Bolivia usandoMachine Learning | MEFP, acceso: abril 3, 2026, https://www.economiayfinanzas.gob.bo/index.php/node/17446
18. encuesta de hogares 2023, eh 2023 - ANDA, acceso: abril 3, 2026, https://anda.ine.gob.bo/index.php/catalog/108/variable/F7/V499?name=s02b_08
19. encuesta de hogares 2023, eh 2023 - ANDA, acceso: abril 3, 2026, https://anda.ine.gob.bo/index.php/catalog/108/variable/F6/V420?name=folio
20. encuesta de hogares 2023, eh 2023 - ANDA - INE, acceso: abril 3, 2026, https://anda.ine.gob.bo/index.php/catalog/108
21. encuesta de hogares 2023, eh 2023 - ANDA, acceso: abril 3, 2026, https://anda.ine.gob.bo/index.php/catalog/108/variable/F6/V434?name=s08a_09
22. encuesta de hogares 2023, eh 2023 - ANDA - INE, acceso: abril 3, 2026, https://anda.ine.gob.bo/index.php/catalog/108/data-dictionary/F3
23. Clasificación de la pobreza en Bolivia, utilizando Random Forest y XGBoost - ResearchGate, acceso: abril 3, 2026, https://www.researchgate.net/publication/378521356_Clasificacion_de_la_pobreza_en_Bolivia_utilizando_Random_Forest_y_XGBoost
24. Despliegue de un modelo en la nube con Streamlit Cloud - Codificando Bits, acceso: abril 3, 2026, https://codificandobits.com/tutorial/despliegue-en-la-nube-streamlit-cloud/
25. How to build an MLOps pipeline? - LeewayHertz, acceso: abril 3, 2026, https://www.leewayhertz.com/mlops-pipeline/
26. Encuesta de Hogares - INE, acceso: abril 3, 2026, https://www.ine.gob.bo/index.php/estadisticas-sociales/vivienda-y-servicios-basicos/encuestas-de-hogares-vivienda/
27. Census income classification with XGBoost — SHAP latest documentation, acceso: abril 3, 2026, https://shap.readthedocs.io/en/latest/example_notebooks/tabular_examples/tree_based_models/Census%20income%20classification%20with%20XGBoost.html
28. MLOps - Machine Learning Best Practices for Public Sector Organizations, acceso: abril 3, 2026, https://docs.aws.amazon.com/whitepapers/latest/ml-best-practices-public-sector-organizations/mlops.html
29. MLOps Best Practices - MLOps Gym: Crawl | Databricks Blog, acceso: abril 3, 2026, https://www.databricks.com/blog/mlops-best-practices-mlops-gym-crawl
30. Streamlining your MLOps pipeline with GitHub Actions and Arm64 runners, acceso: abril 3, 2026, https://github.blog/enterprise-software/ci-cd/streamlining-your-mlops-pipeline-with-github-actions-and-arm64-runners/
31. [GitHub Actions Series #27] MLOps Pipelines with GitHub Actions — Model Training, Evaluation, and Deployment | by Bharat Puri | Medium, acceso: abril 3,

2026, https://medium.com/@bhpuri/github-actions-series-27-mlops-pipelines-with-github-actions-model-training-evaluation-acff1fd8d2fb
32. Análisis de características de MLOps: CI/CD con Acciones de GitHub - Microsoft Learn, acceso: abril 3, 2026, https://learn.microsoft.com/es-es/shows/ai-show/mlops-feature-dive-cicd-with-github-actions
33. Despliegue de modelos de machine learning en entornos de producción - SEE, acceso: abril 3, 2026, https://see-ec.org/wordpress/producto/despliegue-de-modelos-de-machine-learning-en-entornos-de-produccion/
34. Despliegue de Modelos de Machine Learning con Streamlit y Flask, acceso: abril 3, 2026, https://prezi.com/p/6krmex3cuj2o/despliegue-de-modelos-de-machine-learning-con-streamlit-y-flask/
35. Desarrollo y despliegue de modelo de reconocimiento de dígitos con Streamlit - Kopuru, acceso: abril 3, 2026, https://kopuru.com/desarrollo-y-despliegue-de-modelo-de-reconocimiento-de-digitos-con-streamlit/
36. End-to-End MLOps Architecture Design Guide - AWS, acceso: abril 3, 2026, https://aws.amazon.com/video/watch/0ed9d2d9b05/
37. Bolivia en la era de la IA, acceso: abril 3, 2026, https://internetbolivia.org/file/2026/03/Bolivia-en-la-era-de-la-IA.pdf